

El SRE que nunca duerme

**Agentes de IA sobre tu stack de observabilidad open source en
Kubernetes**

Andrés Zeballos · KCD Lima Perú 2026

7:04 p.m.

Cierras la laptop. Terminaste por hoy.

\$15,000

se pierden por CADA minuto que un sistema está caído

\$600 mil millones al año entre las 2,000 empresas más grandes del mundo — +50% en solo dos años · Splunk / Oxford Economics, mayo 2026

34%

de tu semana se va en **toil: la chamba manual y repetitiva que
no construye nada**

Reiniciar pods a mano, revisar alertas falsas, copiar logs a un ticket... · Catchpoint SRE Report: 25% (2024) → 30% (2025) → 34% (2026)

7%

Solo 7 de cada 100 empresas que usan IA generativa la despliegan a diario

82% de las empresas ya corre Kubernetes en producción · 66% de la GenAI del mundo corre sobre Kubernetes · CNCF Annual Survey 2025

\$65,000,000

lo que UNA empresa pagó en UN año — solo por MIRAR sus sistemas

Coinbase · factura Datadog 2022 (estimación JP Morgan) · ¿el final? migró a Prometheus + Grafana — el mismo stack de esta charla

Esta charla es esa noche: de las 7 p.m. a las 3 a.m.

Y la vamos a pasar con tres cosas que esa vez no teníamos:

1. **Un stack open source** que lo ve todo
2. **Un cerebro** que investiga por ti
3. **Control humano** para que no haga tonterías

El elenco de esta noche

	Pieza	Qué hace, en cristiano
Base	OpenTofu	describes tu infraestructura en un archivo, y él la crea por ti
	Argo CD	mantiene el cluster idéntico a lo que dice tu repo Git — si algo se desvía, lo corrige
Telemetría	Prometheus 3	guarda los signos vitales: CPU, memoria, requests por segundo de cada pod
	Grafana 12	las pantallas: ves esos signos vitales y te llegan las alertas
	Fluent Bit 4	junta los logs de todos los pods y los manda a un solo lugar
	OpenTelemetry	el idioma común: métricas, logs y trazas viajan en el mismo formato
IA	K8sGPT	toma los errores del cluster y te los explica en español
	kagent	define agentes de IA en YAML, como cualquier otro recurso de Kubernetes
Modelos	MCP	el enchufe estándar entre el agente y sus herramientas (kubectl, Prometheus...)
	Ollama ↔ Bedrock	dónde vive el modelo: gratis en tu laptop ↔ Claude alquilado en AWS

La escena ya estaba montada — desde hace semanas

🌟 [SS: Argo CD con todas las apps en verde]

- Todo esto se levantó con **dos comandos**: `tofu apply` y Argo CD sincroniza el resto
- **\$0 en licencias** — y el 77% de la industria ya considera clave el open source en observabilidad
- El mismo repo corre en tu laptop o en AWS

7:31 p.m.

Suena el celular. Ni llegaste a la cena.

Los ojos ya estaban abiertos

K8sGPT: lee los errores del cluster y los explica en español.

- Proyecto de la **CNCF** — la misma fundación detrás de Kubernetes
- Funciona con **13+ modelos** distintos, locales o en la nube
- **Diagnostica y sugiere. No aplica cambios.**

7:33 p.m. — el diagnóstico llegó solo

🌟 [SS: salida de `k8sgpt analyze --explain` en español]

"La imagen no existe. Así se arregla." — antes de que encuentres tus lentes.

7:40 p.m. — alguien tiene que investigar. No tienes que ser tú.

kagent: agentes de IA que viven dentro del cluster.

- Lo defines en **YAML**, como cualquier otro recurso de Kubernetes
- Usa herramientas de verdad vía MCP: kubectl, Prometheus, Argo CD
- Proyecto CNCF, creado por Solo.io — el mismo equipo detrás de Istio

El agente investiga solo

🔍 [SS: panel — pregunta en español, respuesta con causa y propuesta]

"¿Por qué falla el pod y qué dice Prometheus del CPU?" → causa raíz + acción propuesta

En una esquina: los open source. En la otra: los propietarios.

- Cambiar de modelo es **un campo en un YAML** (`ModelConfig`)
- Mismo agente, mismas herramientas — **solo cambia quién piensa**
- Gratis en tu laptop · centavos en la nube open source · Claude para lo pesado

¿Cuánto modelo necesita un SRE?

6 incidentes × 7 modelos = 42 diagnósticos medidos

Acertar ya cuesta centavos



13.2 pasos · 39,000
tokens

MiniMax llegó a la respuesta. Nadie sabe cómo.

¿Qué le pasó a MiniMax?

- En agentes no pagas por respuesta: pagas **precio × pasos** — cada vuelta extra son tokens
- MiniMax quemó hasta **39,000 tokens** en un diagnóstico; los directos usan **~5,000**
- Un modelo barato pero caótico te puede costar lo mismo que uno caro y directo

La lección: no llames al SOTA para cada incidente

- Los modelos open source van **3–4 meses** detrás de los mejores — Epoch AI, may 2026
- **9 de los 13** modelos con mejor precio/inteligencia son open source: lo mismo a **1/2–1/6 del precio** — Artificial Analysis, abr 2026
- A capacidad constante, la inferencia se abarata **~10× por año** — a16z

El propietario top, para lo que nadie ha visto antes. El open source, para el turno de noche.

¿Entonces la IA ya resolvió el on-call? No.

- IBM puso agentes a resolver **incidentes reales, complejos y abiertos**: resolvieron **~1 de cada 8** (ITBench, 2025)
- Los mejores modelos del mundo: **menos de la mitad** de aciertos diagnosticando Kubernetes (may 2026)
- Lo que yo mostré son **los fallos de manual** — esos sí ya se diagnostican solos, y por centavos

1:58 a.m. — el fix está listo. ¿Lo dejamos aplicarlo solo?

Todavía no. Y quien te diga lo contrario, te está vendiendo algo.

1. La remediación 100% autónoma **sigue siendo una promesa**, no un producto
2. Gartner: **más del 40%** de los proyectos de agentes de IA serán **cancelados** antes de 2028
3. El freno: **un humano aprueba** antes de tocar el cluster + permisos de solo lectura

Tres preguntas que hoy nadie puede responder

- ¿**Quién es** este agente? — identidad
- ¿**Qué puede tocar** y qué no? — permisos
- ¿**Quién audita** lo que hizo a las 3 a.m.? — trazabilidad

Quiénes ya trabajan en esto: MCP en la Linux Foundation · OWASP MCP Top 10 (beta)
· SPIFFE/SPIRE

[DEMO EN VIVO] No me crean nada: rompámoslo juntos

```
kubectl run roto --image=nginx:noexiste  
k8sgpt analyze --explain --language spanish
```


2:47 a.m. — fix aprobado, cluster en verde. Ahora sí: a dormir.

El repo trae **todo lo de esta charla**, listo para una tarde:

- Las **dos rutas** completas: tu laptop (\$0, offline) y AWS (EKS + Bedrock), mismos YAML
- El **benchmark entero**: código, datos y reporte — corre tus propios 42 diagnósticos
- El guion de comandos paso a paso, y las **fuentes de cada número** que viste hoy

(QR al repo)

Gracias

¿Preguntas?

Fuentes — cada número de esta charla

- [CNCF Annual Cloud Native Survey 2025](#) — 82% · 66% · 7%
- [Splunk / Oxford Economics, Hidden Costs of Downtime](#) — \$15,000/min · \$600B/año
- [Catchpoint, The SRE Report 2026](#) — toil 34% · [Google SRE](#) — tope 50%
- [The Pragmatic Engineer](#) — la factura de \$65M · [Grafana Obs. Survey](#) — 17% del gasto de infra, 77% open source
- [ITBench](#) — [IBM Research, ICML 2025](#) — 11–14% · [ITBench-AA](#) — frontier <50% · [AIOpsLab](#) — [Microsoft](#)
- [Epoch AI](#) — open a 3–4 meses · [Artificial Analysis](#) — 9/13 Pareto, ½–⅓ precio · [a16z](#) — 10×/año
- [Gartner](#) — >40% cancelados para 2027
- **Benchmark propio:** 6 incidentes × 7 modelos — código, datos y reporte en este repo (`demo/bench/`)